

تمرین تحویلی (تاریخ تحویل: ۲۲ تیر)

- دانشجویان گرامی، تمرین مربوط به همین جلسه با عنوان «روش دوم برآورد پارامترهای مدل: بیشینه‌سازی تابع درست‌نمایی» را در مخزنی در **GitHub** که توسط دستیار آموزشی درس، آقای سلمانی، ایجاد و به اشتراک گذاشته شده است، تحویل دهید.
- توجه کنید که به دلیل اهمیت این سری تمرین، نمره آن، وزن ۳ خواهد داشت.

تمارین تحویلی (تاریخ تحویل: ۲۲ تیر) روش دوم بر آورد پارامترهای مدل: بیشینه سازی تابع درستنمایی

در این فعالیت می‌خواهیم برای مدل رگرسیون پواسون (پیش‌بینی تعداد ماهواره‌های خرچنگ نعل‌اسبی)، پارامترهای مدل را به صورت دستی و با استفاده از روش بیشینه‌سازی درست‌نمایی (MLE) تخمین بزنیم.

مدل:

$$\log(\lambda_i) = \beta_0 + \beta_1 C2_i + \beta_2 C3_i + \beta_3 C4_i + \beta_4 S2_i + \beta_5 S3_i + \beta_6 W_i + \beta_7 Wt_i$$

که در آن λ_i میانگین توزیع پواسون برای مشاهده i ام است.

گام ۱: آماده‌سازی داده‌ها و کدگذاری متغیرهای کیفی (Dummy Coding)

در رگرسیون پواسون (و به طور کلی در مدل‌های خطی)، ما نمی‌توانیم نام دسته‌ها یا کدهای عددی ساده (مثل ۱، ۲، ۳) را برای متغیرهای کیفی وارد فرمول کنیم؛ زیرا مدل تصور می‌کند که بین دسته‌ی ۱ و ۲، یک واحد فاصله وجود دارد. برای حل این مشکل، باید از متغیرهای مجازی یا دامی استفاده کنیم.

همان‌طور که در جلسات قبل برای «متغیر تحصیلات» بحث کردیم، قانون کلی این است:

اگر یک متغیر کیفی دارای k سطح (دسته‌بندی) باشد، ما باید $k - 1$ متغیر مجازی برای آن بسازیم. یک سطح همواره به عنوان سطح مرجع (Reference Level) در نظر گرفته می‌شود و ضرایب سایر سطوح نسبت به آن تفسیر می‌گردد.

ادامه تمارین تحویلی (تاریخ تحویل: ۲۲ تیر) روش دوم بر آورد پارامترهای مدل: بیشینه سازی تابع درستنمایی

در فایل داده های خرچنگ، دو متغیر کیفی داریم:

۱. متغیر رنگ ©: این متغیر دارای ۴ سطح است. بنابراین طبق فرمول $k - 1$ ، باید ۳ متغیر مجازی بسازیم. از آنجایی که می خواهیم خروجی تابع خودمان را با تابع `glm` مقایسه کنیم، سطح ۱ را مرجع می گیریم و سه ستون جدید تعریف می کنیم:

- C2: اگر رنگ برابر با ۲ بود، مقدار ۱ و در غیر این صورت ۰ می گیرد.
- C3: اگر رنگ برابر با ۳ بود، مقدار ۱ و در غیر این صورت ۰ می گیرد.
- C4: اگر رنگ برابر با ۴ بود، مقدار ۱ و در غیر این صورت ۰ می گیرد.

این کدگذاری را با دستور `ifelse` در R انجام دهید:

```
C2 = ifelse(C == 2, 1, 0)
C3 = ifelse(C == 3, 1, 0)
C4 = ifelse(C == 4, 1, 0)
```

ادامه تمارین تحویلی (تاریخ تحویل: ۲۲ تیر) روش دوم بر آورد پارامترهای مدل: بیشینه سازی تابع درستنمایی

۲. متغیر وضعیت ستون فقرات (S): این متغیر دارای ۳ سطح است. پس باید ۲ متغیر مجازی (با در نظر گرفتن سطح ۱ به عنوان مرجع) بسازیم:

- S2: اگر وضعیت برابر با ۲ بود، ۱ و در غیر این صورت ۰.
- S3: اگر وضعیت برابر با ۳ بود، ۱ و در غیر این صورت ۰.

```
S2 = ifelse(S == 2, 1, 0)
S3 = ifelse(S == 3, 1, 0)
```

چرا این کار را دستی انجام می دهیم؟

وقتی در R از تابع `glm(Sa ~ C + S + ...)` استفاده می کنید، R خودش به صورت خودکار این ستون های ۰ و ۱ را در حافظه می سازد. اما وقتی می خواهیم تابع درستنمایی را «خودمان» بنویسیم، باید این متغیرها را به صورت شفاف تعریف کنیم تا بتوانیم آن ها را در «ترکیب خطی» ($\beta_1 C_2 + \beta_2 C_3 + \dots$) ضرب کنیم.

گام ۲: نوشتن تابع درست‌نمایی

تابعی به نام `nloglik_loglinear` بنویسید که ورودی آن بردار `theta` (شامل ۸ پارامتر) باشد. داخل تابع:

1. بردار `theta` را به ۸ پارامتر مدل (β_0 تا β_7) تقسیم کنید.
2. یک حلقه `for` برای محاسبه درست‌نمایی هر مشاهده ایجاد کنید.
3. در هر تکرار حلقه، ابتدا `linear_predictor` را محاسبه کنید:

$$\eta_i = \beta_0 + \beta_1 C2_i + \dots + \beta_7 Wt_i$$

4. سپس مقدار λ_i را با استفاده از تابع نمایی به دست آورید:

$$\lambda_i = e^{\eta_i}$$

5. در ادامه، احتمال مشاهده شدن مقدار واقعی `Sa[i]` را با فرض توزیع پواسون محاسبه کنید:

$$P(Sa_i) = \frac{e^{-\lambda_i} \lambda_i^{Sa_i}}{Sa_i!}$$

راهنمایی: در R، تابع `dpois(x, lambda)` مستقیماً این مقدار احتمال را برای شما برمی‌گرداند.

6. در پایان، حاصل ضرب احتمالات تمامی مشاهده‌ها را محاسبه کرده و منفی لگاریتم این حاصل ضرب را برگردانید.

ادامه تمارین تحویلی (تاریخ تحویل: ۲۲ تیر) روش دوم بر آورد پارامترهای مدل: بهینه‌سازی تابع درست‌نمایی

گام ۳: بهینه‌سازی عددی

نقطه‌ی شروع (Initial Values) برای الگوریتم `nlminb` بسیار مهم است.

تمرین: بردار `theta0` را تعریف کنید.

راهنمایی: می‌دانیم که در مدل پواسون، میانگین (λ) برابر با e^{β_0} است (اگر سایر متغیرها صفر باشند). بنابراین بهترین حدس اولیه برای β_0 ، لگاریتم میانگین کل داده‌ها است:

```
log(mean(Sa))
```

سایر ضرایب (β_1 تا β_7) را می‌توانید صفر در نظر بگیرید.

حالا با استفاده از تابع `nlminb`، تابع `nloglik_loglinear` را کمینه کنید (از بازه‌ی `(-Inf, Inf)` برای پارامترها استفاده کنید).

ادامه تمارین تحویلی (تاریخ تحویل: ۲۲ تیر) روش دوم بر آورد پارامترهای مدل: بیشینه سازی تابع درستنمایی

گام ۴: مقایسه با glm

مدل مشابه را با تابع glm برازش دهید:

```
r
```

```
glm(Sa ~ C + S + W + Wt, data = train_data, family = poisson(link = 'log'))
```

پرسش: ضرایب به دست آمده از nlminb را با ضرایب glm مقایسه کنید. آیا دقیقاً یکی هستند؟ اگر تفاوت ناچیزی در حد اعشار دارند، به نظر شما علت آن چیست؟